

Projekt z uczenia maszynowego

Projekt z przedmiotu *Wprowadzenie do uczenia maszynowego* jest **projektem grupowym**, powinien składać się z maksymalnie 3 osób. W szczególnych przypadkach, po uzgodnieniu z prowadzącym, zadania może się podjąć pojedyncza osoba.

Każdy członek zespołu zbiera trzy różne zbiory danych (datasets) na zadany temat, np. nowotwory mózgu – dane mogą być tabelaryczne (forma preferowana) lub w formie zbiorów opisanych zdjęć.

W raporcie należy opisać dane, podając źródło i cechy, oraz znaleźć przynajmniej 3 prace naukowe dotyczące danego zbioru i jego metryk. Następnie każdy wybiera jeden zbiór danych do klasyfikacji lub regresji. Na koniec przedstawia się wyniki w tabeli i wnioski z projektu.

Opis wymagań dla projektu

1. Cel projektu

Celem pracy jest **zbadanie wybranego problemu tematycznego** (np. diagnostyka nowotworów mózgu) poprzez zebranie i analizę różnorodnych publicznych zbiorów danych, a następnie przetestowanie klasycznych lub głębokich metod ML w zadaniu klasyfikacji bądź regresji. Efektem jest raport prezentujący:

- opis i analizę wszystkich pozyskanych danych,
- krótki przegląd literatury z wynikami dotychczasowych badań,
- autorskie eksperymenty, wyniki i ich porównanie,
- wnioski oraz rekomendacje.

2. Organizacja grupy

- Liczba osób w zespole od 1 (po uzgodnieniu) do 3.
- Każdy członek **samodzielnie wyszukuje, pobiera i wstępnie dokumentuje** trzy zbiory danych (tabelaryczne lub obrazy) – **zbiory w grupie nie mogą się powtarzać** (UWAGA: po uzgodnieniu z prowadzącym można zmniejszyć ilość zbiorów).
- Po etapie eksploracji **każdy wybiera jeden ze „swoich” zbiorów** do dalszej analizy modelowej.
- Wspólnie zespół przygotowuje część wprowadzającą, tabelę zbiorczą wyników i wnioski.

3. Wymagania dotyczące zbiorów danych

1. **Źródło:** publiczne repozytorium/naukowy data-portal (np. UCI, Kaggle, TCIA itp.), przy czym w danym źródle należy sprawdzić, czy nie było źródła wcześniejszego.
2. **Opis metadanych** (w tabeli lub akapicie):
 - nazwa i link,
 - licencja,
 - rozmiar (liczba próbek, cech/wymiarów, łączna objętość),
 - typ danych (tabular, obrazy 2D/3D, multimodal),
 - krótkie wyjaśnienie cech / etykiet.

3. **Jakość i przygotowanie:** wspomnieć o brakach danych, balansie klas, pre-processing (skalowanie, kodowanie itp.).

4. Przegląd literatury

Dla **każdego** z wybranych zbiorów danych należy podać **≥ 3 publikacje** (peer-review, konferencja lub czasopismo), które:

- wykorzystują dokładnie ten zbiór (lub jego część),
- raportują mierzalne wyniki (np. accuracy, F1, AUC, MAE). W raporcie należy zacytować i wpisać osiągnięte metryki do tabeli porównawczej.

5. Eksperymenty ML (indywidualne)

- **Dobór zadań:**
 - klasyfikacja – jeśli etykiety dyskretne (np. typ nowotworu),
 - regresja – jeśli etykiety ciągłe (np. czas przeżycia, wielkość guza).
- **Minimalny zakres** (jeden wybrany algorytm):
 - klasyczny (np. Logistic Regression, Random Forest, Linear Regression) lub model bardziej złożony (np. CNN, Gradient Boosting).
 - należy uzasadnić wybór.
- **Preprocessing:** wszystko co konieczne 😊
- **Walidacja:** min. k-fold ($k \geq 5$), train/val/test przy ewentualnym strojeniu hiperparametrów, wykorzystanie stratyfikacji danych oraz jeśli będzie to konieczne zastosowanie właściwych technik dla danych niebalansowanych.
- **Raportowane metryki:** accuracy/F1/AUC lub RMSE/MAE + przedział ufności lub odchylenie std.
- **Reprodukcyjność:** link do kodu (dołączonego pliku).

6. Struktura raportu

- a) **Tytuł** – trzeba wskazać na podstawie zawartości – „zadanie kreatywne”, zatem nie może być tytuł w postaci *Raport z przedmiotu Wprowadzenie do uczenia maszynowego* 😊
- b) **Autorzy** – w kolejności, która później jest kontynuowana
- c) **Wstęp** – kontekst medyczny/tematyczny, motywacja dotycząca danego tematu 😊
- d) **Materiały i metody**
 - Zbiory danych (metadane) - 1 wspólna tabela lub może być w formie opisowej, ale musi być ujednolicone dla wszystkich osób.
 - Wskazanie wybranego zbioru danych i wykorzystanej metody (lub metod) ML oraz najważniejsze informacje o zastosowanych technikach i parametrach (x ilość osób).
- e) **Eksperymenty i wyniki**
 - Benchmarki z literatury – musi być źródło i wskazanie jaką metodę (-y) zastosowano i jakie wyniki osiągnięto (tabela zbiorcza)
 - Wyniki zespołu (tabela zbiorcza)

- f) **Dyskusja** – interpretacja, porównanie z pracami wcześniej
- g) **Wnioski**
- h) **Aneksy** – np. listy cech, dodatkowe informacje lub wykresy jeśli są wymagane.
- i) **Bibliografia** (APA/IEEE)

7. Tabela zbiorcza wyników (przykład)

Lp.	Dataset	Zadanie	Wyniki z literatury – model (odniesienie do bibliografii)	Model z zespołu (podstawowe parametry)	Wynik zespołu
1.1*	ABC 2021	Określenie czasu przeżycia od zakończenia radioterapii	MSE = 1.87 – regresja liniowa (Kowalski et al. 2013) MSE = 1.55 – regresja wielomianowa (Nowak, Iksiński 2018)	Random Forest (200 drzew)	MSE = 1.68 ± 0.01

* nr_osoby_wg_listy_autorów.nr_zbioru_danych

8. Pliki do oddania (w formie zip poprzez platformę Wikamp)

/raport.pdf (.doc) ← gotowy raport

/data/

dataset1/... ← oryginalne pliki (nazwa zbioru) + ewentualne README i inne pliki, jeśli były

dataset2/...

...

/notebooks/

osoba1_dataset.ipynb ← osoba, to imię i nazwisko a dataset, to nazwa zbioru

osoba2_dataset.ipynb

...

/env/requirements.txt ← listy pakietów (pip/conda) jeśli wymagane coś więcej

9. Kod obliczeniowy

- Notatniki Jupyter „**samowystarczalne**”: importy, pobranie danych z lokalnej ścieżki /data/..., uruchamialne w środowisku bez-GPU.
- Komentarze Markdown wyjaśniające kroki – bez szerszych opisów, tabele z podsumowaniami metryk.

10. Wnioski końcowe

Raport musi zawierać **krytyczną analizę**:

- które cechy/dane najbardziej wpłynęły na wynik,
- ograniczenia (np. mała liczebność, bias, overfitting),
- propozycje ulepszeń (większy zbiór, fine-tuning).

Termin oddania: ustalony przez prowadzącego.

Ocena = 40% jakość raportu + 30% poprawność metod (indywidualnie) + 20% dokumentacja kodu (indywidualnie) + 10% estetyka i organizacja repozytorium.

Informacje pomocnicze

Narzędzia:

- **Google Dataset Search:** wyszukiwarka danych (hasło: medical, biomedical, health)
<https://datasetsearch.research.google.com>
- **Papers With Code – Medical:** zestawienie prac z otwartym kodem i danymi
<https://paperswithcode.com/>
- **Google Scholar:** wyszukiwarka publikacji naukowych, <https://scholar.google.pl>

Źródła (przykładowe):

Nazwa	Typ danych	Link
UCI Machine Learning Repository	Dane tabelaryczne, biomedyczne, np. choroba serca, cukrzyca	https://archive.ics.uci.edu/ml/index.php
Kaggle Datasets	Różnorodne (obrazy, EHR, CSV, czasowe, genetyczne)	https://www.kaggle.com/datasets
OpenML	Dane do ML (w tym biomedyczne), klasyfikacja, regresja	https://www.openml.org
Zenodo	Repozytorium danych badawczych, często medycznych	https://zenodo.org
Figshare	Dane badawcze, także kliniczne i genetyczne	https://figshare.com
GEO (Gene Expression Omnibus)	Mikromacierze, RNA-seq, dane genetyczne	https://www.ncbi.nlm.nih.gov/geo/
TCGA (The Cancer Genome Atlas)	Genomika nowotworów (zwykle z obrazami z TCIA)	https://www.cancer.gov/tcga
eICU Collaborative Research Database	Dane z ICU (jak MIMIC), wieloośrodkowe	https://eicu-crd.mit.edu
UK Biobank	Obrazy, dane kliniczne, genotypy – dostęp warunkowy	https://www.ukbiobank.ac.uk
TCIA (The Cancer Imaging Archive)	Obrazy medyczne (MRI, CT, PET), maski, dane onkologiczne	https://www.cancerimagingarchive.net
PhysioNet	Sygnały biomedyczne (EKG, EEG, oddech, ICU), dane kliniczne	https://physionet.org

Warto również w narzędziu **Google Scholar** wyszukać *review* na dany temat hasłami na temat źródeł danych 😊